


PUMA NUCLEI

BIOLOGY-INFORMED FEATURE AUDIT

Báo cáo thống kê chi tiết về morphology, chromatin, spatial và tissue context của 10 lớp nuclei



Tóm tắt: các biological feature trực tiếp có effect size mạnh nhất trong bộ dữ liệu local.

Dataset được phân tích: 97,193 nuclei trên 205 ROI (103 primary + 102 metastatic). Người dùng đã kiểm tra trực tiếp filesystem và xác nhận local dataset không có metastatic_103; vì vậy đây là toàn bộ dữ liệu local hiện có, không phải lỗi matching của script.

Ngày lập báo cáo: 18/08/2026

Tóm tắt điều hành

Mục tiêu của audit là kiểm tra xem các đặc tính sinh học có thể đo được từ nucleus và môi trường xung quanh có tạo ra tín hiệu đủ mạnh để hỗ trợ phân loại 10 lớp nuclei trong PUMA hay không. Đây là full-dataset exploratory analysis: tất cả nuclei local được dùng để mô tả phân bố và đo mức tách lớp; không có train/validation split và không ước lượng khả năng generalize của một model mới.

Kết luận chính: Hướng biology-informed có tín hiệu mạnh và đáng đưa vào Stage 2. Nổi bật nhất là chromatin-gradient, morphology kích thước/trục dài, thống kê tương đối trong ROI, và context tissue/neighbour. Tuy nhiên cần fuse với UNI2 bằng ablation held-out ở bước tiếp theo để chứng minh mức tăng F1 thực tế.


Nhóm	Tín hiệu	Bảng chứng định lượng	Giá trị cho prediction
Chromatin / texture	Rất mạnh	H gradient mean $\epsilon^2=0.289$; H gradient SD $\epsilon^2=0.240$; H SD $\epsilon^2=0.195$	Ưu tiên cao
Morphology	Mạnh	Major axis $\epsilon^2=0.220$; area $\epsilon^2=0.193$; circularity/axis ratio ≈ 0.096	Ưu tiên cao
ROI-relative	Mạnh	H mean ROI percentile $\epsilon^2=0.206$, mạnh hơn H mean raw $\epsilon^2=0.182$	Ưu tiên cao
Spatial geometry	Trung bình-mạnh	kNN-10 distance $\epsilon^2=0.153$; density r100 $\epsilon^2=0.138$	Nên dùng
Neighbour class context	Rất mạnh nhưng oracle	GT neighbour entropy $\epsilon^2=0.283$	Dùng để thiết kế two-pass/GNN, không đưa GT vào inference
Tissue context	Rất mạnh về conditional prior	97.1% tumor nuclei trong tumor; 90.4% epithelium trong epidermis; 74.5% endothelium trong vessel	Dùng predicted tissue probabilities

Các yếu tố được khuyến nghị để tăng khả năng predict

- H gradient mean: feature trực tiếp mạnh nhất ($\epsilon^2=0.289$); phản ánh mức biến thiên chromatin nội nhân.
- H mean ROI percentile: giữ thông tin độ đậm tương đối so với các nuclei cùng ROI ($\epsilon^2=0.206$), giảm ảnh hưởng staining/ROI shift tốt hơn raw intensity đơn lẻ.
- Compact morphology: area/log-area + major-axis + axis-ratio hoặc circularity; tránh đưa cả nhóm feature tương quan cao.
- Nucleus-to-ring H contrast và H Laplacian variance: bổ sung contrast nội nhân - ngoại vi và độ sắc/fragmentation của chromatin.
- Spatial context: kNN-10 distance + một local density scale; cung cấp cấu trúc cellular neighbourhood ngay cả khi chưa biết class hàng xóm.
- Predicted tissue context: dùng vector xác suất tissue, không dùng GT hard-label khi inference.
- Predicted neighbour context: two-pass classifier/GNN dùng soft class probabilities của hàng xóm; GT-neighbour chỉ là oracle evidence.
- Melanin-specific ring features nên được bổ sung riêng cho cặp histiocyte/melanophage; các mean H/E/gray ring hiện tại chưa bắt pigment đủ tốt.

1. Dữ liệu và phạm vi phân tích

Tổng số nucleus: 97,193. Số ROI duy nhất: 205 = 103 primary + 102 metastatic. Local dataset không chứa metastatic_103 theo kiểm tra trực tiếp của người dùng.



Hình 1. Phân bố số lượng nuclei của 10 class trong toàn bộ local dataset.

Class	Số nuclei	Tỷ lệ
Tumor	57,234	58.89%
Lymphocyte	21,643	22.27%
Plasma	520	0.54%
Histiocyte	7,168	7.38%
Melanophages	695	0.72%
Neutrophil	366	0.38%
Stroma	3,856	3.97%
Endothelium	1,696	1.74%
Epithelium	2,211	2.27%
Apoptosis	1,804	1.86%

Class imbalance: Tumor chiếm 58.89%, lymphocyte 22.27%; plasma, neutrophil, melanophages đều <1%. Do đó biology features có thể giúp tăng separability nhưng không thay thế loss/sampling strategy cho rare classes.

2. Các nhóm biology feature được đo

Nhóm	Ví dụ feature	Ý nghĩa sinh học
Morphology	area, perimeter, equivalent diameter, major/minor axis, axis ratio, eccentricity, circularity, solidity, extent	Kích thước, elongation, độ tròn, irregularity
Chromatin / H channel	H mean/P10/P50/P90, H SD/IQR, Sobel-	Độ đậm chromatin, heterogeneity,

Nhóm	Ví dụ feature	Ý nghĩa sinh học
	gradient, Laplacian variance, LBP	edge/fragmentation texture
Perinuclear ring	ring H/E/gray, nucleus-minus-ring H/gray	Contrast nucleus với môi trường ngay ngoài nhân
ROI-relative	percentile, robust-Z của các feature	Nucleus bất thường tới mức nào so với cùng ROI
Spatial	nearest neighbour, kNN 3/5/10, local count/density r25/50/100	Mật độ và topology của cellular neighbourhood
GT neighbour oracle	composition và entropy của class hàng xóm	Chỉ dùng để đo potential của context branch
GT tissue oracle	tumor/stroma/epidermis/vessel/necrosis	Chỉ dùng audit; inference cần predicted tissue probabilities

3. Cách đọc các chỉ số thống kê


Kruskal-Wallis được dùng để kiểm tra sự khác nhau của phân bố feature giữa 10 class. Vì $N \approx 97k$ rất lớn, p-value có thể nhỏ đến mức được lưu thành 0.0 do numerical underflow; do đó report không dùng “ $p < 0.05$ ” làm bằng chứng chính.

Chỉ số	Ý nghĩa	Cách dùng trong report
ϵ^2 (epsilon-squared)	Effect size sau Kruskal-Wallis	Report dùng heuristic thực dụng: ≥ 0.14 mạnh; 0.06-0.14 trung bình; 0.01-0.06 nhỏ; < 0.01 rất nhỏ
Mutual information	Mức thông tin feature mang về class; bất được quan hệ phi tuyến	Cao hơn thường tốt hơn, nhưng có thể bị ảnh hưởng bởi redundancy và sampling
Median/IQR	Vị trí và độ trải robust	Dễ diễn giải sinh học hơn mean khi distribution lệch
ROI percentile / robust-Z	Vị trí tương đối trong cùng ROI	Đặc biệt hữu ích khi staining/scale thay đổi giữa ROI

Giới hạn: Audit này không có held-out validation. Effect size/MI chứng minh biological separability trong dataset, không chứng minh UNI2+biology chắc chắn tăng F1. Mức tăng thật phải đo bằng ablation với cùng split ở Stage 2.

4. Mức tách lớp tổng thể của biological features

Trong 78 feature được kiểm định: 23 feature có $\epsilon^2 \geq 0.14$ (mạnh theo heuristic của report), 31 feature ở 0.06-0.14, 22 ở 0.01-0.06 và chỉ 2 feature < 0.01 . Điều này cho thấy signal biology không tập trung ở một biến đơn lẻ mà xuất hiện đồng thời ở chromatin, morphology và spatial context.




Hình 2. Top deployable features theo ϵ^2 ; GT-neighbour oracle đã được loại khỏi biểu đồ này.

Feature	ϵ^2	MI	Inference	Nhận định
h_gradient_mean	0.289	0.171	Direct	Ưu tiên cao
gt_neighbor_class_entropy	0.283	0.170	Oracle	Không dùng GT trực tiếp
h_gradient_std	0.240	0.149	Direct	Ưu tiên cao
major_axis_length_px	0.220	0.141	Direct	Ưu tiên cao
h_mean_roi_percentile	0.206	0.114	Direct	Ưu tiên cao
perimeter_px	0.205	0.147	Direct	Ưu tiên cao
h_mean_roi_robust_z	0.201	0.116	Direct	Ưu tiên cao
h_std	0.195	0.114	Direct	Ưu tiên cao
h_p90	0.195	0.117	Direct	Ưu tiên cao
area_px	0.193	0.138	Direct	Ưu tiên cao
equivalent_diameter_px	0.193	0.137	Direct	Ưu tiên cao
h_p50	0.188	0.118	Direct	Ưu tiên cao
nucleus_minus_ring_h	0.183	0.107	Direct	Ưu tiên cao
h_mean	0.182	0.104	Direct	Ưu tiên cao
lbp_6	0.176	0.120	Direct	Đáng thử

Feature	ϵ^2	MI	Inference	Nhận định
h_iqr	0.175	0.099	Direct	Đáng thử
h_laplacian_var	0.170	0.100	Direct	Đáng thử
gray_p10	0.162	0.097	Direct	Đáng thử
gray_p50	0.156	0.097	Direct	Đáng thử
knn_10_mean_distance	0.153	0.090	Direct	Đáng thử


Prediction signal nổi bật: h_gradient_mean là direct feature mạnh nhất ($\epsilon^2=0.289$). GT_neighbor_class_entropy gần tương đương ($\epsilon^2=0.283$) nhưng là oracle; kết quả này nên được chuyển thành two-pass neighbourhood aggregation thay vì dùng GT.




Hình 3. “Dấu vân tay” biology của từng class sau khi chuẩn hoá median giữa 10 class.

5. Chromatin / texture: nhóm tín hiệu mạnh nhất


Các feature Hematoxylin-gradient chiếm hai vị trí direct mạnh nhất. Điều này gợi ý rằng không chỉ “nucleus đậm hay nhạt”, mà mức thay đổi cường độ bên trong nhân - biên chromatin, coarse/compact pattern, fragmentation - là tín hiệu quan trọng.



Hình 4. Median H-gradient theo class. Lymphocyte, neutrophil và apoptosis cao nổi bật.



Hình 5. Median H-mean theo class. Lymphocyte có H-mean cao nhất.



Hình 6. Contrast Hematoxylin giữa nucleus và perinuclear ring.

Class	H mean	H grad mean	H grad SD	H SD	H Lap var	Nucleus-ring H
Tumor	0.0970	0.0158	0.0097	0.0223	0.000258	0.0505
Lymphocyte	0.1409	0.0275	0.0167	0.0345	0.000631	0.0857
Plasma	0.1100	0.0203	0.0130	0.0359	0.000356	0.0600
Histiocyte	0.0963	0.0178	0.0108	0.0241	0.000301	0.0489
Melanophage	0.0995	0.0186	0.0112	0.0262	0.000441	0.0478
Neutrophil	0.0854	0.0251	0.0139	0.0318	0.000466	0.0602
Stroma	0.1020	0.0211	0.0125	0.0263	0.000337	0.0635
Endothelium	0.0908	0.0158	0.0099	0.0218	0.000249	0.0464
Epithelium	0.1013	0.0156	0.0100	0.0223	0.000260	0.0460
Apoptosis	0.1142	0.0246	0.0139	0.0323	0.000432	0.0747


Ưu tiên cao cho prediction: Giữ `h_gradient_mean`, `h_std` hoặc một heterogeneity statistic, `h_laplacian_var` và `nucleus_minus_ring_h`. Không cần giữ đồng thời `h_mean`, `h_p50`, `h_p90` vì chúng tương quan rất cao; ROI-percentile của H mean nên được ưu tiên hơn raw quantiles.

6. ROI-relative chromatin: signal mạnh hơn intensity tuyệt đối


H mean raw có $\epsilon^2=0.182$, trong khi H mean ROI percentile đạt $\epsilon^2=0.206$ và robust-Z đạt $\epsilon^2=0.201$. Như vậy câu hỏi “nucleus này đậm hơn bao nhiêu nuclei khác trong cùng ROI?” chứa nhiều thông tin class hơn raw H mean trong dataset hiện tại.

Feature nên dùng: `h_mean_roi_percentile` là lựa chọn compact tốt. Có thể giữ thêm raw `h_mean` nếu muốn preserve absolute intensity, nhưng không cần dùng cả percentile lẫn robust-Z vì hai biến gần như trùng nhau (Spearman $\rho \approx 0.995$).


7. Morphology: kích thước, elongation và độ tròn



Hình 7. Median nuclear area của 10 class.



Hình 8. Axis ratio: stroma và endothelium elongated rõ.



Hình 9. Circularity: stroma/neutrophil thấp; lymphocyte/apoptosis cao.

Class	Area median	Area CV	Major axis	Axis ratio	Circularity	Eccentricity
Tumor	554.0	0.61	33.53	1.50	0.887	0.745
Lymphocyte	320.0	0.38	23.67	1.35	0.918	0.670
Plasma	575.0	0.39	31.99	1.37	0.904	0.681
Histiocyte	452.0	0.50	30.21	1.52	0.869	0.754
Melanophage	540.0	0.49	32.76	1.51	0.874	0.750
Neutrophil	304.0	0.45	26.17	1.58	0.789	0.774
Stroma	352.0	0.53	33.14	2.34	0.713	0.904
Endothelium	495.0	0.51	34.45	1.87	0.807	0.845
Epithelium	559.0	0.49	34.31	1.60	0.858	0.781


Class	Area median	Area CV	Major axis	Axis ratio	Circularity	Eccentricity
Apoptosis	246.5	0.81	21.68	1.36	0.920	0.676

7.1. Những pattern morphology đáng chú ý

- Lymphocyte: area median 320 px², circularity 0.918 - nhỏ và tròn, phù hợp với morphology compact.
- Apoptosis: area median 246.5 px² - nhỏ nhất; nhưng circularity median 0.920 rất cao. Do đó giả định “apoptosis luôn irregular” không được dữ liệu polygon hiện tại ủng hộ.
- Tumor: area median 554 px², mean 629 px², SD 384 px² (CV≈0.61) - distribution kích thước rộng, phù hợp pleomorphism.
- Stroma: axis ratio 2.336, eccentricity 0.904 và circularity 0.713 - dấu hiệu spindle/elongated mạnh nhất.
- Endothelium: axis ratio 1.871, eccentricity 0.845 - elongated nhưng ít cực đoan hơn stroma; tissue context vessel giúp tách rất mạnh.
- Neutrophil: circularity 0.789 và H-gradient cao; có thể phản ánh multi-lobed morphology tốt hơn raw H mean.

Compact morphology set: Ưu tiên area (hoặc log-area) + major-axis + axis-ratio + circularity. Không nên giữ đồng thời area, equivalent-diameter và perimeter; các biến này rất tương quan, và circularity đã sử dụng area/perimeter để encode shape.

8. Tissue context: biological location có tính quyết định cao



Hình 10. Phân bố GT tissue theo nucleus class. Đây là oracle analysis, không phải feature được phép dùng trực tiếp khi inference.


Nucleus	Tissue nổi bật	Tỷ lệ	Giá trị
Tumor	Tumor	97.1%	Rất mạnh
Histiocyte	Stroma	94.4%	Rất mạnh
Endothelium	Blood vessel	74.5%	Rất mạnh
Epithelium	Epidermis	90.4%	Rất mạnh
Lymphocyte	Stroma	76.3%	Mạnh
Melanophage	Stroma	73.7%	Mạnh
Apoptosis	Tumor / Necrosis	62.1% / 18.6%	Rất hữu ích
Neutrophil	Stroma / Necrosis	59.3% / 6.6%	Hữu ích

8.1. Necrosis và “nuclear integrity”

Apoptosis có 18.6% nuclei nằm trong necrosis, cao hơn rõ so với đa số class. Neutrophil có 6.6%. Tuy nhiên necrosis không phải nucleus class; vì vậy không nên hard-code “nằm trong necrosis = apoptosis”.

Cách dùng để tăng predict: Thay GT tissue bằng soft predicted tissue vector từ tissue model: P(tumor), P(stroma), P(epidermis), P(vessel), P(necrosis). Có thể bổ sung distance-to-necrosis và necrosis fraction quanh nucleus.

9. Neighbourhood context: bằng chứng mạnh cho two-pass/GNN




Hình 11. GT neighbour-class composition. Các ô chéo cao cho thấy class có xu hướng clustering; đây là oracle analysis.

Center class	Same-class neighbour	Global prevalence	Enrichment
Tumor	86.5%	58.89%	1.5×
Lymphocyte	57.9%	22.27%	2.6×
Plasma	30.7%	0.54%	57.4×
Histiocyte	36.9%	7.38%	5.0×
Melanophages	18.1%	0.72%	25.3×
Neutrophil	26.8%	0.38%	71.2×
Stroma	25.1%	3.97%	6.3×
Endothelium	35.7%	1.74%	20.4×
Epithelium	81.7%	2.27%	35.9×
Apoptosis	33.0%	1.86%	17.8×

Các rare classes có enrichment đặc biệt mạnh: neutrophil ~71×, plasma ~57×, epithelium ~36×, melanophages ~25×, endothelium ~20× so với prevalence toàn dataset. Đây là bằng chứng trực tiếp rằng cellular neighbourhood không ngẫu nhiên và có thể giúp rare-class classification.

9.1. Spatial geometry đã có signal ngay cả khi chưa biết class hàng xóm




Hình 12. Median kNN-10 distance theo class; lymphocyte/plasma/histiocyte có neighbourhood dày hơn, melanophages thưa hơn.

Spatial feature	ϵ^2	MI
knn_10_mean_distance	0.153	0.090
knn_5_mean_distance	0.151	0.089
knn_3_mean_distance	0.146	0.083
local_count_r100	0.138	0.086
local_density_r100	0.138	0.086
nn_distance	0.121	0.150

Feature nên dùng ngay: kNN-10 mean distance + một local-density scale (ví dụ r=100). Chúng deployable trực tiếp từ centroid predictions và không cần biết GT class.

Feature oracle nên chuyển hoá: GT_neighbor_class_entropy $\epsilon^2=0.283$ rất mạnh nhưng không được dùng trực tiếp. Hướng đúng là pass-1 tạo soft class probabilities, aggregate probability/entropy theo distance, rồi pass-2 refine class; hoặc dùng cell graph attention.

10. Primary vs metastatic: distribution shift rõ rệt



Hình 13. Class composition khác nhau đáng kể giữa primary và metastatic trong local dataset.

Class	Primary N	Primary %	Metastatic N	Metastatic %
Tumor	22,601	46.10%	34,633	71.90%
Lymphocyte	13,023	26.56%	8,620	17.90%
Plasma	45	0.09%	475	0.99%
Histiocyte	6,178	12.60%	990	2.06%
Melanophage	454	0.93%	241	0.50%
Neutrophil	111	0.23%	255	0.53%
Stroma	2,760	5.63%	1,096	2.28%
Endothelium	1,292	2.64%	404	0.84%
Epithelium	2,211	4.51%	0	0.00%
Apoptosis	353	0.72%	1,451	3.01%

Rủi ro source prior: Tumor chiếm 71.90% metastatic nhưng 46.10% primary; histiocyte 12.60% primary nhưng 2.06% metastatic; epithelium xuất hiện 4.51% primary và 0% metastatic. Một context model quá mạnh có thể học “đây là metastatic” thay vì học morphology thật.

Không dùng sample_type làm class shortcut: Primary/metastatic nên được dùng để stratify evaluation hoặc domain analysis, không nên feed trực tiếp như một class-prediction feature trong thiết kế mặc định.

Khi kiểm chứng model sau này, cần split theo ROI và kiểm tra performance theo source để bảo đảm gain của biology branch không đến từ leakage. Audit full-dataset hiện tại vẫn phù hợp cho mục đích mô tả biological separability.

11. Hồ sơ biology của từng class

Tumor

Lớn, biến thiên kích thước rộng; H-gradient tương đối thấp; 97.1% nằm trong tumor tissue; neighbour thường là tumor (86.5%). Pleomorphism thể hiện rõ ở dispersion hơn là một giá trị size cố định.

Lymphocyte

Nhỏ, tròn, H mean và H-gradient cao nhất; mật độ local cao, kNN gần; 76.3% trong stroma. Đây là class có “compact/dark/clustered” signature rõ.

Plasma

Area median lớn (575 px²), H SD cao nhất trong các median; neighbour enrichment rất lớn (~57×) dù rare. Context immune + chromatin heterogeneity có thể hữu ích.

Histiocyte

Size trung bình-lớn, shape gần melanophage; 94.4% trong stroma. Cặp histiocyte/melanophage khó tách chỉ bằng morphology.

Melanophage

Lớn, shape gần histiocyte; neighbourhood sparse hơn (kNN-10 median ~69.9). Ring H/E/gray mean hiện có effect thấp, cho thấy cần pigment-specific melanin features thay vì mean ring đơn giản.

Neutrophil

Nhỏ-vừa, circularity thấp, H-gradient cao; same-class neighbour enrichment ~71×; 6.6% nằm trong necrosis. Multi-lobed texture/context có vẻ quan trọng hơn raw H mean.

Stroma

Spindle signature mạnh nhất: axis ratio 2.336, eccentricity 0.904, circularity 0.713. Morphology rất có giá trị.

Endothelium

Elongated (axis ratio 1.871) nhưng không cực đoan như stroma; 74.5% nằm trong blood vessel tissue, nên tissue context là discriminator then chốt.


Epithelium

Area lớn, morphology tương đối regular; 90.4% trong epidermis và neighbour epithelium ~81.7%. Tissue + neighbourhood gần như định danh mạnh.

Apoptosis

Area nhỏ nhất (246.5 px²), H-gradient cao, H contrast nucleus-ring cao; 62.1% tumor và 18.6% necrosis. Circularity cao cho thấy không nên hard-code “apoptosis = irregular polygon”.

12. Redundancy: không nên đưa cả 78 feature vào Stage 2



Hình 14. Correlation heatmap của các feature candidate trên sample 30k nuclei. Các cặp $|\rho| \geq 0.90$ được ghi số.

Cặp feature	Spearman ρ	Khuyến nghị
area ↔ equivalent diameter	1.000	Chọn area/log-area
axis ratio ↔ eccentricity	1.000	Chọn axis ratio
local count r100 ↔ local density r100	1.000	Chọn density
H mean ↔ H P50	0.996	Chọn H mean hoặc ROI percentile
H ROI percentile ↔ H ROI robust-Z	0.995	Chọn percentile
area ↔ perimeter	0.974	Giữ area + circularity; bỏ perimeter nếu cần compact
H mean ↔ H P90	0.977	Không cần cả quantile set
kNN3 ↔ kNN5	0.963	Chọn một scale; ưu tiên kNN10 cho context rộng hơn

Cặp feature	Spearman ρ	Khuyến nghị
H SD ↔ H IQR	0.960	Chọn H SD
H gradient mean ↔ H gradient SD	0.939	Ưu tiên gradient mean
kNN10 ↔ local density r100	-0.923	Có overlap nhưng khác representation; thử giữ cả hai rồi ablate

Nguyên tắc: Feature có ϵ^2 cao không có nghĩa nên giữ nếu nó chỉ là bản sao của một feature khác. Compact feature set giúp giảm overfit, giảm latency và giúp ablation dễ diễn giải hơn.

13. Compact biology feature set khuyến nghị cho Stage 2

Prediction-oriented recommendation matrix

Factor	ϵ^2	Inference availability	Recommendation
H gradient mean	0.289	Direct	Very high
H mean ROI percentile	0.206	Direct	Very high
Major axis length	0.220	Direct	High
Area / log-area	0.193	Direct	High
H SD / heterogeneity	0.195	Direct	High
Nucleus-ring H contrast	0.183	Direct	High
H Laplacian variance	0.170	Direct	High
kNN-10 mean distance	0.153	Direct	Medium-high
Local density r100	0.138	Direct	Medium-high
Axis ratio / circularity	0.096	Direct	Medium
Predicted tissue context		Predicted context	Very high
Predicted neighbour context		Predicted context	Very high
GT neighbour entropy	0.283	Oracle only	Do not use directly

Hình 15. Ma trận khuyến nghị prediction-oriented.

Nhóm	Feature	Evidence	Vai trò	Khuyến nghị
Morphology	log(area_px)	~0.193 (raw area)	Kích thước; log transform giảm skew	Giữ
Morphology	major_axis_length_px	0.220	Length/elongation bổ sung cho area	Giữ
Morphology	axis_ratio	0.096	Spindle/elongated, đặc biệt stroma/endothelium	Giữ
Morphology	circularity	0.097	Roundness/multilobed shape	Giữ
Chromatin	h_gradient_mean	0.289	Direct feature mạnh nhất	Giữ - ưu tiên cao
Chromatin	h_std	0.195	Heterogeneity	Giữ
Chromatin	h_laplacian_var	0.170	Sharpness/fragmentation	Giữ

Nhóm	Feature	Evidence	Vai trò	Khuyến nghị
			proxy	
ROI-relative	h_mean_roi_percentile	0.206	Relative chromatin intensity trong ROI	Giữ - ưu tiên cao
Perinuclear	nucleus_minus_ring_h	0.183	Contrast nucleus-vs-context	Giữ
Spatial	knn_10_mean_distance	0.153	Local spacing/context	Giữ
Spatial	local_density_r100	0.138	Local cell density	Giữ/ablate với KNN10
Tissue	predicted tissue probability vector	Oracle conditional signal	Tissue prior mềm	Giữ - từ tissue model
Neighbour	predicted neighbour prob/entropy	GT oracle $\epsilon^2=0.283$	Two-pass/GNN context	Giữ - không dùng GT
Pigment (mới)	melanin OD / brown-pixel fraction	Chưa đo	Mục tiêu histiocyte ↔ melanophages	Nên bổ sung

13.1. Những feature nên bỏ khỏi compact set do redundancy

- equivalent_diameter_px: $\rho=1.000$ với area; không thêm thông tin ranking.
- perimeter_px: effect mạnh nhưng $\rho \approx 0.974$ với area; circularity đã tận dụng perimeter theo cách shape-aware.
- eccentricity: $\rho=1.000$ với axis_ratio trong data hiện tại; chọn một.
- h_p50/h_p90/h_iqr: overlap lớn với h_mean/h_std; chỉ giữ nếu ablation chứng minh gain riêng.
- h_mean_roi_robust_z: $\rho \approx 0.995$ với percentile; ưu tiên percentile dễ diễn giải.
- local_count_r100: tương đương local_density_r100 theo radius cố định; chỉ giữ density.
- KNN3/kNN5: correlation cao với KNN10; compact set chỉ cần một scale ban đầu.

13.2. Architecture implication

Một thiết kế hợp lý là giữ UNI2 làm appearance encoder, thêm Biology MLP cho compact numeric features, thêm predicted tissue probabilities và spatial context. Neighbour context nên đi qua pass-2 hoặc graph attention để tránh dùng oracle labels.

Thứ tự ablation nên ưu tiên: E0 UNI2 baseline → E1 + morphology → E2 + chromatin/ROI-relative → E3 + predicted tissue → E4 + spatial → E5 + two-pass neighbour → E6 + melanin-specific. Mọi experiment dùng cùng ROI split và cùng training protocol.

14. Đánh giá từng hướng ban đầu của nghiên cứu

Ý tưởng	Kết luận sau audit	Bằng chứng / cách dùng
Cân bằng màu / contrast	Có ích nhưng chưa phải ưu tiên số 1	H-channel features đã rất mạnh; ROI-relative H còn tăng effect. Nên giữ RGB gốc + H-based branch thay vì chỉ normalize ảnh.
Ảnh hưởng tế bào xung quanh	Rất đáng đầu tư	GT neighbour entropy $\epsilon^2=0.283$; rare classes có same-class enrichment 18-71×.
Size/perimeter/area/texture	Được dữ liệu ủng hộ mạnh	Major axis $\epsilon^2=0.220$; area 0.193; H gradient 0.289; H SD 0.195.
Hoại tử / nuclear integrity	Có signal nhưng cần mô hình hoá đúng	Apoptosis 18.6% trong necrosis; neutrophil 6.6%. Dùng necrosis probability/distance, không hard-rule class.

Ý tưởng	Kết luận sau audit	Bằng chứng / cách dùng
Primary vs metastatic	Quan trọng như domain/source factor, không nên là shortcut class feature	Class priors khác rất mạnh; cần stratified reporting và grouped validation.

15. Kết luận cuối cùng

Audit trên toàn bộ local dataset cho thấy 10 class nuclei có các biological signatures định lượng khác nhau rõ rệt. Chromatin-gradient là direct signal mạnh nhất; morphology và ROI-relative intensity cũng có effect lớn; tissue và neighbourhood tạo conditional structure rất mạnh. Vì vậy biology-informed branch có cơ sở dữ liệu đủ tốt để được thử nghiệm nghiêm túc trong Stage 2.

Tuy nhiên mục tiêu tiếp theo không phải đưa toàn bộ 78 feature vào model. Hướng hợp lý là compact feature engineering + predicted context, sau đó ablation đối chứng với UNI2 baseline. Chỉ khi UNI2+biology tăng macro-F1 trên ROI-held-out split mới có thể kết luận biological branch thực sự cải thiện model thay vì chỉ mô tả lại signal mà UNI2 đã học.

Khuyến nghị ưu tiên thực thi: 1) h_gradient_mean + h_std + H ROI percentile; 2) area/major-axis/axis-ratio/circularity; 3) nucleus-ring H; 4) predicted tissue vector; 5) kNN/density; 6) two-pass neighbour probabilities; 7) melanin-specific features cho melanophages.

Phụ lục A. Top 30 features theo effect size

Rank	Feature	ϵ^2	MI	Loại
1	h_gradient_mean	0.2891	0.1708	Direct
2	gt_neighbor_class_entropy	0.2831	0.1697	Oracle
3	h_gradient_std	0.2404	0.1494	Direct
4	major_axis_length_px	0.2199	0.1406	Direct
5	h_mean_roi_percentile	0.2059	0.1136	Direct
6	perimeter_px	0.2054	0.1468	Direct
7	h_mean_roi_robust_z	0.2013	0.1160	Direct
8	h_std	0.1955	0.1137	Direct
9	h_p90	0.1945	0.1172	Direct
10	area_px	0.1933	0.1381	Direct
11	equivalent_diameter_px	0.1933	0.1372	Direct
12	h_p50	0.1884	0.1176	Direct
13	nucleus_minus_ring_h	0.1833	0.1067	Direct
14	h_mean	0.1817	0.1035	Direct
15	lbp_6	0.1756	0.1199	Direct
16	h_iqr	0.1755	0.0991	Direct
17	h_laplacian_var	0.1698	0.0997	Direct

Rank	Feature	ϵ^2	MI	Loại
18	gray_p10	0.1624	0.0969	Direct
19	gray_p50	0.1561	0.0974	Direct
20	knn_10_mean_distance	0.1534	0.0900	Direct
21	knn_5_mean_distance	0.1510	0.0891	Direct
22	knn_3_mean_distance	0.1465	0.0827	Direct
23	minor_axis_length_px	0.1430	0.1130	Direct
24	perimeter_px_roi_percentile	0.1386	0.1479	Direct
25	local_count_r100	0.1384	0.0862	Direct
26	local_density_r100	0.1384	0.0857	Direct
27	gray_mean	0.1341	0.0773	Direct
28	local_density_r50	0.1320	0.0835	Direct
29	local_count_r50	0.1320	0.0819	Direct
30	area_px_roi_percentile	0.1304	0.1530	Direct

Phụ lục B. Lưu ý diễn giải và tái lập

- Các số liệu trong report được đọc trực tiếp từ output của PUMA nuclei biology audit ZIP do người dùng cung cấp.
- Local dataset: 205 ROI; người dùng xác nhận không có metastatic_103. Report không cố “bù” bằng dữ liệu ngoài.
- GT tissue và GT neighbour là oracle diagnostic variables, không được coi là inference-ready feature.
- p-value=0.0 trong CSV là numerical underflow ở N lớn, không phải xác suất toán học đúng bằng 0.
- Các threshold ϵ^2 trong report là heuristic thực dụng để sắp ưu tiên, không phải một chuẩn duy nhất tuyệt đối.
- Mọi kết luận về “tăng prediction” trong report là mức tiềm năng/khuyến nghị dựa trên separability; gain cuối cùng cần held-out model ablation.